Email kliens fejlesztés - Projektmunka

Fejlesztői dokumentáció

Tóth Balázs - MWZX0D

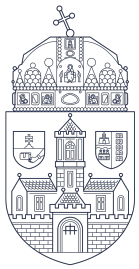

ÓBUDAI EGYETEM
ÓBUDA UNIVERSITY

Tartalomjegyzék

1. Projektek

1.1 Technológiák

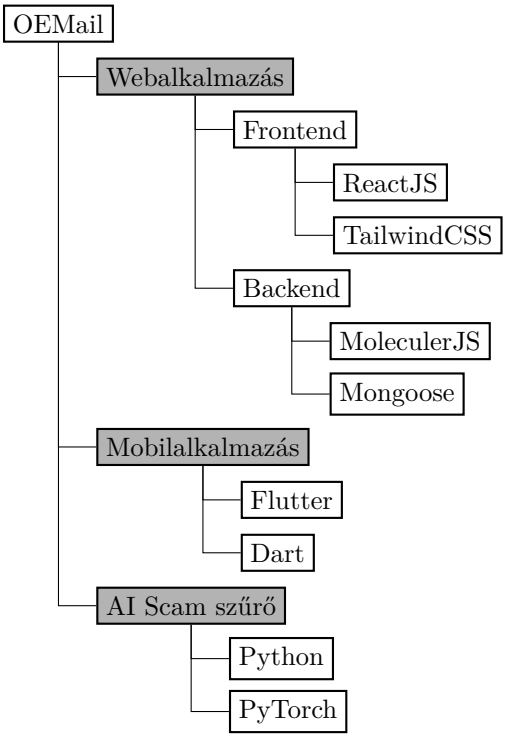

1.2 Szoftverek

- **Docker**
  - **Compose** miatt szükséges a használata
  - **https://docs.docker.com/get-docker/**
- **Postman**
  - API végpontok teszteléséhez
  - **https://www.postman.com/downloads/**
- **MongoDBCompass**
  - Adatbázis menedzsment
  - **https://www.mongodb.com/products/tools/compass**
- **Visual Studio Code** (*ajánlott*)
  - Fejlesztői környezet
  - **https://code.visualstudio.com/download**

1.3 Előkövetelmények, csomagok, keretrendszerek

1.3.1 Webalkalmazás

- NodeJS
  - **https://nodejs.org/en**

1.3.2 AI Scam szűrő

- Python
  - **https://www.python.org/downloads/**
- Pip
  - **https://pip.pypa.io/en/stable/installation/**
- torch
- scikit-learn
- numpy
- pandas
- matplotlib
- flask

2. Összehasonlítások

Funkció/Egyéb	OEMail	GMail	ProtonMail
Mobilon működik	✅	✅	✅
Dedikált autentikátor	✅	✅	❌
Ingyenes spam szűrő API	✅	❌	❌

Tábla 2.1: Szolgáltatások közti különbségek

3. DNS szerver

3.1 Indítás

Ahhoz, hogy használni tudjuk az email klienst, kritikus fontosságú a DNS szervernek a futtatása. Természetesen arra vonatkozik ez a megkötés, ha lokálisan futtatjuk az email szervert!

- `docker-compose up -d`

Parancs futtatása után látható, hogy sikeresen elindult a DNS szerver.

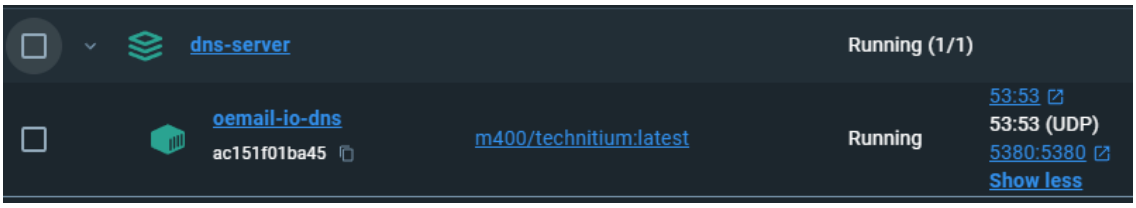

3.2 Konfiguráció

Magát a konfigurációt webes környezetben hajthatjuk végre, amely látható is, hogy a **5380** porton fut. Cím, amelyen a konfigurációt elvégezhetjük:

- `http://localhost:5380/`

3.2.1 Zóna hozzáadása

Megadott paraméterek:

- Zóna neve: `oemail.io`
- Típus: `Primary Zone`

3.2.2 Rekordok hozzáadása

Korábban létrehozott `oemail.io` zónához rekordok hozzáadása szükséges az email szerverhez.

- `MX` típusú rekord paraméterei:
  - Name: `@` (rámutat az aktuális DNS rekordra)
  - TTL: `3600` (1 óra)
  - Preference: `10`
  - Exchange: `mail.oemail.io`
- `A` típusú rekord paraméterei:
  - Name: `mail`
  - TTL: `3600` (1 óra)
  - IPv4 Address: `127.0.0.1`

3.2.3 Tesztelés nslookup parancs segítségével

Az alábbi parancs segítségével tesztelhetjük a korábban beállított paramétereket: `nslookup mail.oemail.io`

MX rekord paraméterek ellenőrzése: `nslookup -type=mx oemail.io 127.0.0.1`

4. SMTP, IMAP szerver

4.1 hMailServer

Be kell kapcsolni az SMTP, IMAP protokollokat, ezután meg kell adni a megfelelő domain nevét: `oemail.io`. Itt hozhatunk létre IMAP fiókokat is, amit az `Accounts` menüpontban tehetünk meg.

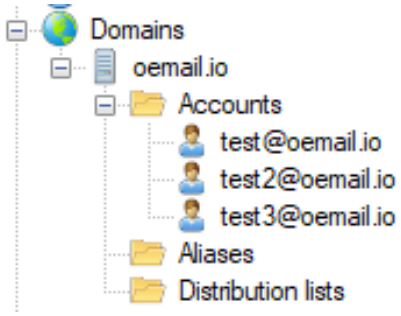

4.2 Alapértelmezett mappák

Új fiók regisztrációja során az alábbi mappák kerülnek létrehozásra:

- **INBOX**: Bejövő emailek.
- **SENT**: Elküldött emailek.
- **TRASH**: Szemét, törölt emailek.
- **SPAM**: Gyanús emailek.
- **STARS**: Kedvenc emailek.

5. Backend

5.1 Bejelentkezés

- Végpont - **/api/users/login**
  - **POST** (JSON)
- Előfeltétel(ek): **Nincs**
- Bemeneti paraméter(ek):
  - email - Típus: **email**
  - password - Típus: **string**

```
{
    "email": "test2@oemail.io",
    "password": "test"
}
```

Kód 5.1: Példa adatok a bejelentkezéshez

5.2 Regisztráció

- Végpont - **/api/users/**
  - **POST** (JSON)
- Előfeltétel(ek): **Nincs**
- Bemeneti paraméter(ek):
  - user - Típus: **object**

```
{
    "user": {
        "email": "test2@oemail.io",
        "password": "test",
        "firstName": "Test2",
        "lastName": "Test2"
    }
}
```

Kód 5.2: Példa adatok a regisztrációhoz

5.3 Adott email lekérése mappából

- Végpont - **/api/mail/getEmailByMailBox**
  - **POST** (JSON)
- Előfeltétel(ek): **Felhasználói bejelentkezés (token)**
- Bemeneti paraméter(ek):
  - mailBoxName - Típus: **string**

```
{
    "mailBoxName": "INBOX"
}
```

Kód 5.3: Példa adatok a legújabb email lekérésére adott mappából

5.4 Összes email lekérése mappából

- Végpont - **/api/mail/getAllEmailByMailBox**
  - **POST** (JSON)
- Előfeltétel(ek): **Felhasználói bejelentkezés (token)**
- Bemeneti paraméter(ek):
  - mailBoxName - Típus: **string**

```
{
    "mailBoxName": "INBOX"
}
```

Kód 5.4: Példa adatok az összes email lekérésére adott mappából

5.5 Email törlése mappából

- Végpont - **/api/mail/deleteMessage**
  - **DELETE** (JSON)
- Előfeltétel(ek): **Felhasználói bejelentkezés (token)**
- Bemeneti paraméter(ek):
  - mailBoxName - Típus: **string**

```
{
    "mailBoxName": "INBOX"
}
```

Kód 5.5: Példa adatok adott email törlésére mappából

5.6 Spam szűrés

- Végpont - **/api/mail/filterInboxFromSpam**
  - **POST** (JSON)
- Előfeltétel(ek): **Felhasználói bejelentkezés (token)**
- Bemeneti paraméter(ek):
  - mailBoxName - Típus: **string**

```
{
    "mailBoxName": "INBOX"
}
```

Kód 5.6: Példa adatok spam emailek szűrésére

5.7 Mappa létrehozása

- Végpont - **/api/mail/createMailBox**
  - **POST** (JSON)
- Előfeltétel(ek): **Felhasználói bejelentkezés (token)**
- Bemeneti paraméter(ek):
  - mailBoxName - Típus: **string**

```
{
    "mailBoxName": "INBOX"
}
```

Kód 5.7: Példa adatok mappa létrehozására

5.8 Mappák lekérése

- Végpont - **/api/mail/listMailboxes**
  - **GET**
- Előfeltétel(ek): **Felhasználói bejelentkezés (token)**
- Bemeneti paraméter(ek):
  - Nincs

6. AI Scam szűrő API

6.1 Tanítási adatok felépítése

Maga a bemeneti fájl egy `csv` kiterjesztésű fájl, mely tartalmaz `Text` és `Class` besorolásokat. A `Text` besorolás jelzi az email üzenetet. A `Class` besorolás pedig két értékkel bírhat: `0` és `1`. A `0` érték jelzi, hogy az adott email üzenet nem veszélyes, csak egy általános email üzenet. `1`-es érték jelzi a scam email üzenetet.

Fontossága a tanításnak, hogy maga az API képes legyen meghatározni, hogy majd a bejövő email üzenet káros-e vagy sem, ezáltal védi meg a felhasználót, hogy ne kattintson potenciális veszélyes email-re.

6.2 Modell

Konstruktoron belül, három teljesen összekapcsolt (lineáris) réteget határozunk meg. Ezek a rétegek felelősek a bemeneti adatok átalakításáért a megtanúlt súlyok segítségével:

- **self.fc1** → Az `input_dim` dimenziójú bemenetet fogadja és 64 dimenziós kimenetet állít elő.
- **self.fc2** → Az `fc1` kimenetét veszi (64 dimenzió) és egy 32 dimenziós kimenetet állít elő.
- **self.fc2** → Az `fc2` kimenetét veszi (32 dimenzió) és létrehozza a 2 dimenziós végső kimenetet, amely két osztályt (0 és 1) képvisel.

```
1      import torch
2      import torch.nn as nn
3
4      class TextClassifier(nn.Module):
5          def __init__(self, input_dim):
6              super(TextClassifier, self).__init__()
7              self.fc1 = nn.Linear(input_dim, 64)
8              self.fc2 = nn.Linear(64, 32)
9              self.fc3 = nn.Linear(32, 2)
10
11         def forward(self, x):
12             x = torch.relu(self.fc1(x))
13             x = torch.relu(self.fc2(x))
14             x = self.fc3(x)
15             return x
```

Kód 6.1: Szövegosztályozó modell

A `forward` metódus meghatározza a neurális hálózat haladási irányát. Vár egy `x` tenzor paramétert, és minden egyes definiált rétegnek átadja azt a `rectified linear unit (ReLU)` aktiválás függvény (`torch.relu`) segítségével. Ezután a végső eredményt adja vissza, ami a hálózat kimenete.

```
    def forward(self, x):
        x = torch.relu(self.fc1(x))
        x = torch.relu(self.fc2(x))
        x = self.fc3(x)
        return x
```

Kód 6.2: Forward metódus

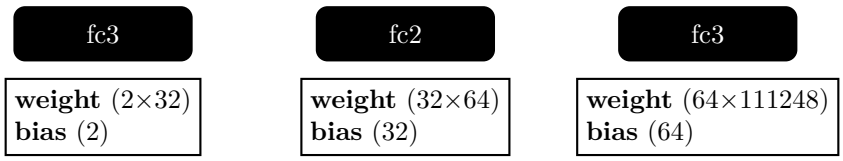

Ábra 6.1: Modell súlyok

6.3 Tanítás

Először is beolvasásra kerülnek a tanítási adatok, melyek 'Text' és 'Class' értékekből állnak, így ezeket el kell szeparálni egymástól.

```
    data = pd.read_csv('fraud_email_.csv')

    data['Text'].fillna('', inplace=True)

    texts = data['Text'].tolist()
    labels = data['Class'].tolist()
```

Kód 6.3: Tanítási adatok betöltése csv fájlból

Létre kell hozni egy `CountVectorizer()` példányt, mely szöveges dokumentumok gyűjteményét alakítja át mátrixba, ahol minden sor egy dokumentmot és minden oszlop egy egyedi szót a korpuszban reprezentál. Majd a `fit_transform` metódus segítségével illesztjük a `vectorizer`-t a megadott szöveges adathoz (`texts`) és átalakítjuk a szöveges adatot egy mátrixba (`X`).

Hogy később fel lehessen használni ezen adatokat a későbbiekben, szükséges menteni őket: `count_vectorizer_vocab.pkl`; `count_vectorizer.pkl` néven. A `count_vectorizer_vocab.pkl` egy szótár, amely a szavakat indexeikkel társítja a mátrixban. A `count_vectorizer.pkl` tartalmazza a szótárt és a hozzátartozó szükséges egyéb paramétereket/konfigurációkat.

```
    vectorizer = CountVectorizer()
    X = vectorizer.fit_transform(texts)

    with open('count_vectorizer_vocab.pkl', 'wb') as vocab_file:
        pickle.dump(vectorizer.vocabulary_, vocab_file)

    with open('count_vectorizer.pkl', 'wb') as vectorizer_file:
        pickle.dump(vectorizer, vectorizer_file)
```

Kód 6.4: Beolvasott adatok előfeldolgozása

Adatok konverzálása PyTorch tenzorokká, ahol először az `X` változó kerül átalakításra a `torch.tensor` segítségével. Így eredményül kapunk egy sűrűbb tenzort. Ezt követően a `dtype=torch.float32` beállításával biztosítjuk, hogy a tenzor elemei lebegőpontos számok legyenek. Az `y` változót is PyTorch tenzorrá alakítjuk, de `int64` típust használunk, mert ezek a címkék osztályokat jelentenek.

Adatok felosztása tanító és teszt halmazokra a `train_test_split` függvény segíttségével. Az `X_train` és a `y_train` változók tartalmazzák a tanító adathalmazt, míg az `X_test` és `y_test` változók a teszt adathalmazt. A `test_size=0.2` azt jelenti, hogy a teszt halmaz a teljes adathalmaz 20%-át fogja tartalmazni és a `random_state=42` a véletlenszerűség vezérlésére szolgál, így az eredmények ismételhettőek lesznek.

Bemeneti dimenzió és modell létrehozása, ahol az `input_dim` változóban eltároljuk a bemeneti dimenziót, ami a tanító adathalmazban lévő jellemzők számát jelenti. Ezután létrehozunk a már korábban létrehozott modellt (`TextClassifier`) és átadjuk paraméterként a bemeneti dimenziót.

```
    X = torch.tensor(X.toarray(), dtype=torch.float32)
    y = torch.tensor(labels, dtype=torch.int64)

    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

    input_dim = X_train.shape[1]
    model = TextClassifier(input_dim)
```

Kód 6.5: PyTorch tenzorok

Először létrehozunk egy `nn.CrossEntropyLoss` példányt, ami felel a veszteségekért. Azért került használatra, mert jól alkalmazható osztályozási problémákra, ahol az egyes példányok egyetlen helyes kategóriákhoz tartoznak.

Az optimalizáló algoritmust az `optim.Adam` osztály segítségével hozzuk létre. Az Adam egy hatékony optimalizáló algoritmus, amely alkalmazodik a tanítás során változó `gradiens`hez [1]. A `model.parameters()` az összes tanítható paramétert jelöli meg a modellben és ezeket fogja optimalizálni az algoritmus. Az `lr=0.001` paraméter beállítja a tanulási ráta értékét, ami azt szabályozza, hogy mennyire legyenek nagyok a lépésközök a paraméterek frissítésekor.

```
1       criterion = nn.CrossEntropyLoss()
2       optimizer = optim.Adam(model.parameters(), lr=0.001)
```

Kód 6.6: Vesztéség és optimalizáló algoritmus definiálása

Maga a tanulási fázis egy cikluson keresztül megy végig (`num_epochs`) és minden epoch kezdetén a gradiensek nullázódnak, hogy ne akkumulálódjanak az epochok között (`optimizer.zero_grad()`). A modell előrejelzéseket hoz létre a tanító adathalmozon (`outputs = model(X_train)`). A `loss = criterion(outputs, y_train)` kiszámolja a veszteséget a modell előrejelzések és a valós címkék között a meghatározott veszteségfüggvény segítségével.

A `loss.backward()` visszaterjeszti (backpropagation) a gradienseket a hálózaton, azaz kiszámolja a veszteségfüggvény parciális deriváltját a paraméterek szerint. Az `optimizer.step()` optimalizációs algoritmus végrehajtja a paraméterek frissítését a tanító adathalmozon kiszámolt gradiensek alapján. Végül a veszteség értékét hozzáadjuk a `train_losses` listához és elmentjük a tanítási eredményeket a `spam_classifier_model.pth` néven.

```
1       num_epochs = 20
2       train_losses = []
3
4       for epoch in range(num_epochs):
5           optimizer.zero_grad()
6           outputs = model(X_train)
7           loss = criterion(outputs, y_train)
8           loss.backward()
9           optimizer.step()
10          train_losses.append(loss.item())
11          print(f'Epoch [{epoch + 1}/{num_epochs}], Loss: {loss.item():.4f}')
12
13      torch.save(model.state_dict(), "spam_classifier_model.pth");
```

Kód 6.7: Tanítási ciklus

[1] A gradiens egy vektor, amely tartalmazza egy függvény minden paraméterének parciális deriváltját egy adott pontban.

A `torch.max` függvény segítségével megkeressük azokat a kimeneti oszlopokat, amelyekben a legnagyobb értékek vannak. A második visszatérési érték a maximális érték indexeit tartalmazza. Ezek az indexek az osztályokhoz tartozó előrejelzések.

A pontosság kiszámításánál az `accuracy_score` felel. Tehát összehasonlítjuk a modell által előrejelzett osztályokat (`predicted`) a valós osztályokkal (`y_test`), majd kiszámoljuk a pontosságot.

```
model.eval()
with torch.no_grad():
    y_pred = model(X_test)
    _, predicted = torch.max(y_pred, 1)

accuracy = accuracy_score(y_test.numpy(), predicted.numpy())
print(f'Accuracy: {accuracy * 100:.2f}%')
```

Kód 6.8: Modell kiértékelése

6.4 Spam szűrése

- Végpont - **/spam-classification**
  - **POST** (JSON)
- Előfeltétel(ek): **Nincs**
- Bemeneti paraméter(ek):
  - text - Típus: **string**

```
{
    "text": "SAMPLE TEXT"
}
```

Kód 6.9: Példa adatok a spam üzenet szűrésére

7. Környezet és annak kialakítása

7.1 WSL telepítése

A Docker szoftverhez szükséges a WSL telepítése.

1. WSL engedélyezése PowerShell-ben

```
dism.exe /online /enable-feature
↪ /featurename:Microsoft-Windows-Subsystem-Linux /all /norestart
```

Kód 7.1: WSL engedélyezése

2. Virtual Machine Platform engedélyezése

```
dism.exe /online /enable-feature /featurename:VirtualMachinePlatform /all
↪ /norestart
```

Kód 7.2: VMP engedélyezése

3. Ubuntu telepítése WSL segítségével

4.
```
wsl --install -d Ubuntu
```

Kód 7.3: Ubuntu WSL

Kódjegyzék

Ábrajegyzék

Táblajegyzék