

Mesterséges Intelligencia Alapú Spam Szűrőfejlesztés Neuro-lingvisztikus Megközelítéssel PyTorch Keretrendszer segítségével

Tóth Balázs
Neumann János Informatikai Kar
Óbudai Egyetem
Magyarország, Budapest
mwzx0d@stud.uni-obuda.hu

Póser Valéria
Neumann János Informatikai Kar
Óbudai Egyetem
Magyarország, Budapest
poser.valeria@nik.uni-obuda.hu

Absztrakt—A tanulmány bemutatja a PyTorch-alapú mesterséges intelligencia spam szűrő fejlesztését, melynek alapját a neuro-lingvisztikus megközelítések képezik, azaz a természetes nyelvi feldolgozás (NLP). Olyan modell került lefejlesztésre, mely segítségével könnyedén ki lehet szűrni a gyanúsnak tűnő üzeneteket.

Kulcsszavak—PyTorch, modell, fejlesztés, NLP, spam

I. BEVEZETÉS

A digitális kommunikáció mára már szinte elengedhetlenné vált az emberek mindennapi életében. Sajnos ezzel párhuzamosan a spam üzenetek terjedése is exponenciálisan növekszik, ezzel kihívást állítva a rendszerekre, amelyek a nemkívánatos tartalmakat szűrik. Kritikus fontosságú, hogy az adott szoftver amit használunk az üzenetek küldésére és fogadására, az megbízhatóan szűrje azokat.

A tanulmány azt mutatja be, hogy hogyan alkalmazható a PyTorch keretrendszer és a természetes nyelvi feldolgozási megközelítések összehangoltan egy intelligens spam szűrő rendszer kialakítására. Segítségével a bemeneti adatok alapján képes megtanulni, hogy az általunk megadott adatok alapján melyek vannak besorolva általános vagy gyanús üzenetként.

II. MÓDSZERTAN

A. Adatgyűjtés és előkészítés

Első és legfontosabb az adatgyűjtés, hiszen ez az alapja a mesterséges intelligenciának, ezek alapján tud tanulni. A gyűjtött adatok tartalmazzák a spam és nem spam kategóriák reprezentatív mintáit. Az adatforrás felépítése tartalmazza az üzenetet és a besorolást. A besorolás lehetséges értékei 0 és 1, ahol a 0-ás érték jelöli az általános üzenetet és az 1-es érték, hogy gyanús, vagyis spam üzenet.

Az adatok előkészítése során a felesleges részeit az üzenetnek el kell távolítani.

B. PyTorch-alapú modell fejlesztése

A modellnek meg kell adni, hogy milyen dimenziójú bemenettel kell számolnia. Belátható, hogy a modellnek három rétege van, melyek teljesen összekapcsolt rétegek, amik alkotják a neurális hálózatot és a `forward` függvényen keresztül halad át a bemeneti adatokon. Tegyük fel, hogy az `input_dim` értéke 100, így annak 100 elemű vektorral kell rendelkeznie, ami az első réteget illeti.

```
class TextClassifier(nn.Module):
    def __init__(self, input_dim):
        super(TextClassifier, self).__init__()
        self.fc1 = nn.Linear(input_dim, 64)
        self.fc2 = nn.Linear(64, 32)
        self.fc3 = nn.Linear(32, 2)

    def forward(self, x):
        x = torch.relu(self.fc1(x))
        x = torch.relu(self.fc2(x))
        x = self.fc3(x)
        return x
```

Ábra 1. Modell Python kód tartalma

Első réteg (`fc1`), ahol az `input_dim` dimenziójú bemeneteket fogadja és 64 dimenziójú kimenetet generál a rektifikált lineáris egység (ReLU) ($H = \max(0, X)$) aktivációs függvényvel. A második réteg (`fc2`) 64 dimenziójú bemeneteket fogad és 32 dimenziós kimenetet generál, szintén az előző réteg módszere szerint. A harmadik réteg (`fc3`) 32 dimenziójú bemeneteket fogad és 2 dimenziójú kimenetet generál, így ez a végső réteg, vagyis nem kell további aktivációs függvényt alkalmazni, ezáltal a kimenetet visszaadjuk.

C. Természetes nyelvi feldolgozás integrációja

D. Tanulási folyamat

E. Modell értékelése

F. Finomhangolás és optimalizálás

III. EREDMÉNYEK

IV. MEGVITATÁS

HIVATKOZÁSOK

- [1] Basemah Alshemali and Jugal Kalita, *Improving the Reliability of Deep Neural Networks in NLP: A Review*, Knowledge-Based Systems, 2020.